

Machine Learning

Assignment 03: Probability Review

Übung 01

Beweis: $Var(X) = E(X^2) - (E(X))^2$

Vorgabe: $\mu = E(X)$

$$Var(X) = E((X - \mu)^2) = E\left((X - E(X))^2\right) = E\left(X^2 - 2 * X * E(X) + (E(X))^2\right)$$

$$Var(X) = E(X^2) - 2E(X * E(X)) + E\left((E(X))^2\right)$$

$$Var(X) = E(X^2) - 2 * E(X) * E(X) + E\left((E(X))^2\right)$$

$$Var(X) = E(X^2) - 2 * (E(X))^2 + (E(X))^2$$

$$Var(X) = E(X^2) - (E(X))^2$$

Übung 02

Beweis: $Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y)$

Vorgabe: $\mu_X = E(X), \mu_Y = E(Y), Var(X) = E((X - \mu_X)^2)$

$$Var(X + Y) = E((X + Y - \mu_X - \mu_Y)^2) = E\left((X - \mu_X)(Y - \mu_Y)\right)^2$$

$$Var(X + Y) = E((X - \mu_X)^2 + 2(X - \mu_X)(Y - \mu_Y) + (Y - \mu_Y)^2)$$

$$Var(X + Y) = E((X - \mu_X)^2) + E((Y - \mu_Y)^2) + E(2(X - \mu_X)(Y - \mu_Y))$$

$$Var(X + Y) = Var(X) + Var(Y) + 2E((X - \mu_X)(Y - \mu_Y))$$

$$Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y)$$

$$E((X - \mu_X)(Y - \mu_Y)) = E(XY - X\mu_Y - \mu_X Y + \mu_X \mu_Y) = E(XY) - E(X\mu_Y) - E(\mu_X Y) + E(\mu_X \mu_Y)$$

$$E((X - \mu_X)(Y - \mu_Y)) = E(XY) - \mu_Y E(X) - \mu_X E(Y) + \mu_X \mu_Y E(1)$$

$$E((X - \mu_X)(Y - \mu_Y)) = E(XY) - E(Y) * E(X) - E(X) * E(Y) + E(X) * E(Y)$$

$$E((X - \mu_X)(Y - \mu_Y)) = E(XY) - E(X) * E(Y) = Cov(X, Y)$$

Übung 03

Beweis: Kovarianz Matrix ist immer symmetrisch und positiv semi-definiert.

Vorgabe: $C = E((x - \bar{x})(x - \bar{x})^T)$, beliebiger Vektor $v \in R^n$

$$v^T C v = v^T E((x - \bar{x})(x - \bar{x})^T) v = E(v^T (x - \bar{x})(x - \bar{x})^T v) = E(s^2) = \sigma_s^2$$

$$\sigma_s = v^T (x - \bar{x}) = (x - \bar{x})^T v$$

$$\Rightarrow v^T C v = \sigma_s^2 \geq 0$$

qed.

Aus der Definition der Kovarianz-Matrix: $\sum_{i,j} = E_{x \sim p}[(x_i - \mu_j)(x_i - \mu_j)]$

geht hervor, dass die Reihenfolge keine Rolle spielt, also dass $\sum_{i,j} = \sum_{j,i}$ ist, und damit ist die Kovarianz-Matrix symmetrisch.

Machine Learning

Assignment 03: Probability Review

Übung 04

$$f(x) = \begin{cases} 1/b - a & , a \leq x \leq b \\ 0 & , \text{sonst} \end{cases}$$

$$1 = \int_a^b 1/b - a \, dx = \left[\frac{x}{b-a} \right]_a^b = \frac{b-a}{b-a} = 1 \quad \text{qed.}$$

Übung 05

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & , 0 \leq x \leq \infty \\ 0 & , \text{sonst} \end{cases}$$

$$1 = \lim_{h \rightarrow \infty} \int_0^h \lambda e^{-\lambda x} \, dx = \lim_{h \rightarrow \infty} [-e^{-\lambda x}]_0^h = \lim_{h \rightarrow \infty} -e^{-\lambda h} - (-e^{-\lambda \cdot 0}) = 0 - (-1) = 1 \quad \text{qed.}$$

Übung 06

Seien X_1, X_2, \dots, X_n beliebige unabhängige und identische, Poisson-verteilte Zufallsvariablen mit $P(X = x) = \frac{\lambda^x e^{-\lambda}}{x!}$.

Gesucht: Das λ , das die Wahrscheinlichkeit von X_1, X_2, \dots, X_n maximiert.

$$L(p|x_1, \dots, x_n) = \prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda}$$

$$L(p|x_1, \dots, x_n) = \ln \left(\prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = \sum_{i=1}^n \ln \left(\frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = \sum_{i=1}^n \ln(\lambda^{x_i}) - \ln(x_i!) + \ln(e^{-\lambda})$$

$$L(p|x_1, \dots, x_n) = \sum_{i=1}^n x_i * \ln(\lambda) - \ln(x_i!) - \lambda = \ln(y) * \sum_{i=1}^n x_i - \sum_{i=1}^n \ln(x_i!) - \sum_{i=1}^n \lambda$$

$$L(p|x_1, \dots, x_n) = \ln(\lambda) * n * \bar{x} - \sum_{i=1}^n \ln(x_i!) - n * \lambda \quad \text{mit } \bar{x} = \text{Durchschnitt aller } x_i$$

$$\frac{dL}{d\lambda} = 1/\lambda * n * \bar{x} - n \quad \frac{dL}{dp} = 0$$

$$0 = 1/\lambda * n * \bar{x} - n \quad | /n \quad \text{mit } n \neq 0 \text{ und } \lambda > 0$$

$$0 = 1/\lambda * \bar{x} - 1 \quad | + 1$$

$$1 = 1/\lambda * \bar{x} \quad | * \lambda$$

$$\lambda = \bar{x}$$

$$\frac{d^2 L}{d\lambda d\lambda} = -\frac{1}{\lambda^2} * n * \bar{x} < 0 \quad \forall \lambda, \text{ da } n > 0 \text{ und } x_i \in N_0 \quad \forall i \in \{1, \dots, n\}$$

L hat somit ein globales Maximum an der Stelle $\lambda = \bar{x} = \text{mean}(x_1, \dots, x_n)$.

Machine Learning

Assignment 03: Probability Review

Übung 07

Vorgabe: $E(X) = 0$, $Cov(x) = Var(X) = I$, $E(Y) = \mu$, $Cov(Y) = Var(Y) = \sigma I$

Gesucht: $E(Z)$ und $Var(Z)$, wobei $Z = AX + Y$

$$E(Z) = E(AX + Y) = E(AX) + E(Y) = A * E(X) + E(Y) = A * 0 + \mu = \mu$$

$Var(Z) = Var(AX + Y) = A^2 * Var(X) + Var(Y) + 2A * Cov(X, Y) = A^2 * I + \sigma I = A^2 + \sigma * I$
, da X und Y unabhängig voneinander sind ist $Cov(X, Y) = 0$.

Übung 08

$$X, Y \sim U[0,1] \text{ mit } E(\min(X, Y)) = \frac{1}{2} * E(X + Y - |X - Y|)$$

$$E(\min(X, Y)) = \frac{1}{2} * (E(X) + E(Y) - E(|X - Y|)) = \frac{1}{2} * \left(\frac{1}{2} + \frac{1}{2} - E(|X - Y|)\right)$$

$$E(\min(X, Y)) = \frac{1}{2} * (1 - E(|X - Y|)) = \frac{1}{2} - \frac{1}{2} * E(|X - Y|) = \frac{1}{2} - \frac{1}{2} E(Z) \quad \text{mit } Z = |X - Y|$$

$$g(X, Y) = |X - Y| = \begin{cases} X - Y, & X \geq Y \\ Y - X, & X < Y \end{cases}$$

$$f_{x,y}(X, Y) = f_x(X) * f_y(Y) \quad , \text{ da } X \text{ und } Y \text{ unabhängig sind.}$$

$$f_x(X) = f_y(Y) = \begin{cases} 1, & x \in [0,1] \\ 0, & \text{sonst} \end{cases}$$

$$f_{x,y}(X, Y) = 1 \text{ in } [0,1] \times [0,1]$$

$$\Rightarrow E(Z) = E(g(X, Y))$$

$$E(Z) = \int_0^1 \int_0^1 g(X, Y) f_{x,y}(X, Y) dX dY = \int_0^1 \int_0^1 |X - Y| dX dY$$

$$E(Z) = \int_0^1 \int_0^x (X - Y) dY dX + \int_0^1 \int_x^1 (Y - X) dY dX = \frac{1}{6} + \frac{1}{6} = \frac{1}{3}$$

$$\Leftrightarrow \frac{1}{2} - \frac{1}{2} * E(Z) = \frac{1}{2} - \frac{1}{6} = \frac{1}{3}$$