

Algorithmen, Wahrscheinlichkeit und Information

Chernoff Bounds

Annahmen:

- $X = \sum_{i=1}^n X_i$ X_i unabhängig
- X_i können verschieden verteilt sein
- $0 \leq X_i \leq 1 \leftarrow$ ohne Beweis!
- $\mu = E[X] = \sum_{i=1}^n E[X_i]$

Zusammenfassung der Chernoff-Methode

- Nicht $P[X > c]$, sondern $P[e^X > e^{t \cdot c}]$
- $E[e^X] = E[e^{\sum_i X_i}] = \prod_i E[e^{X_i}]$
- Wähle t so, dass WSK möglichst klein wird
- $P[X \geq (1+\delta) \mu] \leq e^{-\frac{\mu \delta^2}{3}}$
- $P[X \leq (1-\delta) \mu] \leq e^{-\frac{\mu \delta^2}{3}}$
- $P[|X - \mu| \geq \delta \cdot \mu] \leq 2 \cdot e^{-\frac{\mu \delta^2}{3}}$

Bsp.: Wettervorhersage trifft zu an jedem Tag mit WSK 0.75

Jemand behauptet: Stimmt am Sa/So nie!

\Rightarrow Prognose stimmt nur an höchstens $\frac{5}{7}$ Tage

$X_1, \dots, X_n : X_i$ Indikator-ZV dafür, dass die Prognose stimmt an Tag i

$$X = \sum_{i=1}^n X_i$$

$$P_{X_i}(1) = \frac{3}{4} \quad E[X] = \mu = \frac{3}{4} \cdot n$$

$$P[\text{"Prognose stimmt höchstens an } \frac{5}{7} \text{ Tagen"}] = P[X \leq \frac{5}{7} \cdot n]$$

$$\frac{5}{7} \cdot n = (1 - \delta) \cdot \mu = (1 - \delta) \cdot \frac{3}{4} \cdot n$$

$$\Leftrightarrow \delta = \frac{1}{21}$$

$$\Rightarrow P[X \leq \frac{5}{7} \cdot n] = P[X \leq (1 - \frac{1}{21}) \cdot \frac{3}{4} \cdot n] \leq e^{-\frac{\mu \delta^2}{3}} = e^{-\frac{3}{4} \cdot \frac{1}{441} \cdot \frac{1}{3} \cdot n}$$

- 1 Jahr = 365 Tage \rightarrow WSK = 0,81
- 10 Jahr = 3650 Tage \rightarrow WSK = 0,12
- 20 Jahr = 7300 Tage \rightarrow WSK = 0,016

Für welche Abweichung (δ) ergibt ein Chernoff-Bound eine geg. WSK ε ?

$$P[\dots] \leq e^{-\frac{\mu\delta^2}{3}} = \varepsilon$$

- ε : Fehler-WSK
- δ : Abweichung vom Erwartungswert
- μ : Erwartungswert

$$\begin{aligned} \Delta(\mu, \varepsilon)? \\ e^{-\frac{\mu\delta^2}{3}} &= \varepsilon \\ \frac{\mu\delta^2}{3} &= \ln\left(\frac{1}{\varepsilon}\right) \\ \delta &= \sqrt{\frac{3}{\mu} \cdot \ln\left(\frac{1}{\varepsilon}\right)} \\ \Rightarrow \Delta(\mu, \varepsilon) &= \sqrt{\frac{3}{\mu} \cdot \ln\left(\frac{1}{\varepsilon}\right)} \end{aligned}$$

X_i Bernoulli-Experiment mit WSK p

$$\mu = E[X] = n \cdot p$$

Fehler WSK möglichst klein:

$$\begin{aligned} \Delta(\mu, e^{-n}) &= \sqrt{\frac{3}{n \cdot p} \cdot n} = \sqrt{\frac{3}{p}} \text{ nicht möglich} \\ \Delta(\mu, n^{-c}) &= \sqrt{\frac{3}{n \cdot p} \cdot \ln(n^c)} = \sqrt{\frac{3}{n \cdot p} \cdot c \cdot \ln(n)} = \sqrt{\frac{3c}{p} \cdot \frac{\ln(n)}{n}} \end{aligned}$$

$$\delta = \frac{1}{21} \text{ mit Fehler-WSK} = n^{-2}$$

$$\Delta(\mu, n^{-2}) = \sqrt{\frac{3 \cdot 2}{\frac{3}{4}} \cdot \frac{\ln(n)}{n}} = \sqrt{8 \cdot \frac{\ln(n)}{n}}$$

- 365 Tage $\rightarrow \varepsilon = 7,5 \cdot 10^{-6} \rightarrow \delta = 0,35$
- 1000 Tage $\rightarrow \varepsilon = 10^{-6} \rightarrow \delta = 0,23$
- 3650 Tage $\rightarrow \varepsilon = 7,5 \cdot 10^{-8} \rightarrow \delta = 0,13$
- 7300 Tage $\rightarrow \varepsilon = 1,8 \cdot 10^{-8} \rightarrow \delta = 0,099$

Balls and Bins

m Bälle und n Töpfe, wobei $m \gg n$

X_i Anzahl Bälle in T_i

$$E[X_i] = \frac{m}{n} \text{ für jedes } T_i$$

Mit hoher WSK ist X_i "nicht viel größer" als $\frac{m}{n}$; wie viel größer? (und mit welcher WSK?)

$$X_i = \sum_{j=1}^m X_{ij} \text{ Indikator für Ball } j \text{ in Topf } i$$

$$P_{X_{ij}}(1) = \frac{1}{n}$$

$$E[X_{ij}] = \frac{1}{n} \quad \text{Var}[X_{ij}] = \frac{1}{n} - \frac{1}{n^2}$$

$$\text{Var}[X_i] = \sum_{j=1}^m \text{Var}[X_{ij}] = \frac{m}{n} - \frac{m}{n^2}$$

$$\underline{\text{Chebyshev}} \Rightarrow P[X_i \geq \frac{m}{n} + l] = P[|X_i - \frac{m}{n}| \geq l] \leq \frac{\text{Var}[X_i]}{l^2} \leq \frac{m}{n} \cdot \frac{1}{l^2}$$

Bsp. (Markov): $m = 10^6, n = 10^3, l = 250$

$$P[X_i \geq 1250] \leq 0,016$$

Chernoff-Bound

Lemma:

$$\Rightarrow P[X_i \geq \frac{m}{n} + 3 \cdot \sqrt{\ln(n)} \cdot \sqrt{\frac{m}{n}}] \leq \frac{1}{n^3}$$

Beweis:

$$P[X_i \geq (1 + \delta) \cdot \mu] \leq e^{-\frac{\mu \delta^2}{3}}$$

$$\delta \cdot \mu = \delta \cdot \frac{m}{n} := 3 \cdot \sqrt{\ln(n)} \cdot \sqrt{\frac{m}{n}}$$

$$\delta = \frac{3 \cdot \sqrt{\ln(n)}}{\sqrt{\frac{m}{n}}}$$

$$\varepsilon = e^{-\frac{\mu \delta^2}{3}} = e^{-\frac{9 \cdot \ln(n)}{3 \cdot \frac{m}{n}} \cdot \frac{m}{n}} = e^{-3 \cdot \ln(n)} = n^{-3} = \frac{1}{n^3}$$

Bsp. (Chernoff): $m = 10^6, n = 10^3, l = 250$

$$P[X_i \geq \frac{m}{n} + l] = P[X_i \geq 1000 + 250] \leq 10^{-9}$$

Kombination von Chernoff-Bound mit Union-Bound

"Fehlerereignisse" B_1, B_2, \dots, B_n , die alle kleine WSK (mit Chernoff-Bound)

$$P[B_1 \cup B_2 \cup \dots \cup B_n] \leq \sum_{i=1}^n P[B_i]$$

Falls $P[B_i]$ "sehr sehr klein" und "viele" solcher Ereignisse auftreten können, dann ist Gesamtfehler-WSK "sehr klein"

Bsp.: n Fehler und $P[B_i] \leq 2^{-\frac{n}{2}}$

$$P[\bigcup_i B_i] \leq n \cdot 2^{-\frac{n}{2}} \in O(2^{-\frac{n}{2}})$$

$$P[B_i] = \varepsilon \in O(n^{-c})$$

$$P[\bigcup_i B_i] \leq n \cdot \varepsilon \in O(n^{-c+1})$$

Bsp.: Server-Farm mit n Servern und m Jobs, welche statisch aber zufällig auf k Server verteilt werden

Storage-Array mit n Disks und m Blocks, die zu verteilen sind (uniform und zufällig)

Entspricht Modell: Balls and Bins

X_i ZV für Anzahl Bälle in T_i

$$M = \max\{X_1, \dots, X_n\}$$

$$P[M \geq \frac{m}{n} + l] \leq ?$$

$$P[M \geq \frac{m}{n} + l] \leq n \cdot P[X - i \geq \frac{m}{n} + l] \leq n \cdot \frac{1}{n^3} = \frac{1}{n^2}$$

WSK dafür, dass irgend ein T_i mehr als 1'250 Bälle enthält $\leq 10^{-6}$.